Model Performance Evaluation: A Comparative Study of Classification Models Beyond Overall Accuracy

Tomás Ferreira
2025168427

Eduardo Pereira
2021233890

Visualização para Inteligência Artificial

Universidade de Coimbra
Faculdade de Ciências e Tecnologia

Chapter 1

Enquadramento, Dados e Processo de Design

1.1 Introdução e Enquadramento do Problema

Os modelos de classificação em *machine learning* são frequentemente avaliados através de métricas globais como *accuracy*, *precision*, *recall* ou *F1-score*. Embora úteis, estas métricas fornecem apenas uma visão parcial do comportamento dos modelos. Na prática, modelos com valores globais semelhantes podem comportar-se de forma muito diferente quando o *threshold* de decisão varia, quando se analisam tipos específicos de erro ou quando o desempenho é avaliado em diferentes subgrupos da população. Assim, uma avaliação baseada apenas em métricas agregadas pode ocultar compromissos importantes, riscos operacionais e potenciais problemas de viés.

Este projeto aborda esta limitação através do desenvolvimento de um *Model Evaluation Dashboard* centrado na análise de modelos de classificação para além da *accuracy* global. O sistema permite a comparação direta entre dois modelos — Logistic Regression e Random Forest — e disponibiliza vistas coordenadas que suportam a exploração interativa do desempenho. Em vez de apresentar apenas valores estáticos, o dashboard permite analisar como as métricas evoluem com o *threshold* de decisão, como se manifestam os diferentes tipos de erro e como o desempenho varia entre grupos demográficos.

O público-alvo deste sistema inclui analistas de dados, profissionais de *machine learning* e *stakeholders* que necessitam de compreender o comportamento dos modelos de forma transparente e fundamentada. O dashboard é concebido como uma ferramenta de *visual analytics* que apoia a comparação, a exploração e a tomada de decisão informada, em vez de se focar na fase de treino ou otimização dos modelos.

O sistema foi concebido para responder a questões centrais, tais como: que modelo apresenta melhor desempenho segundo diferentes critérios? Como variam as métricas quando o *threshold* é alterado? Que tipos de erro são mais frequentes e em que condições ocorrem? Existem grupos demográficos sistematicamente desfavorecidos pelas decisões do modelo? Ao responder a estas questões através

de visualizações interativas e coordenadas, o dashboard pretende proporcionar uma compreensão mais rica e fiável do desempenho dos modelos de classificação.

A Figura 1.1 apresenta uma visão geral da interface final do dashboard, que integra todas as vistas num ambiente unificado para comparação global, exploração de *trade-offs*, análise de erros e avaliação de *fairness*.

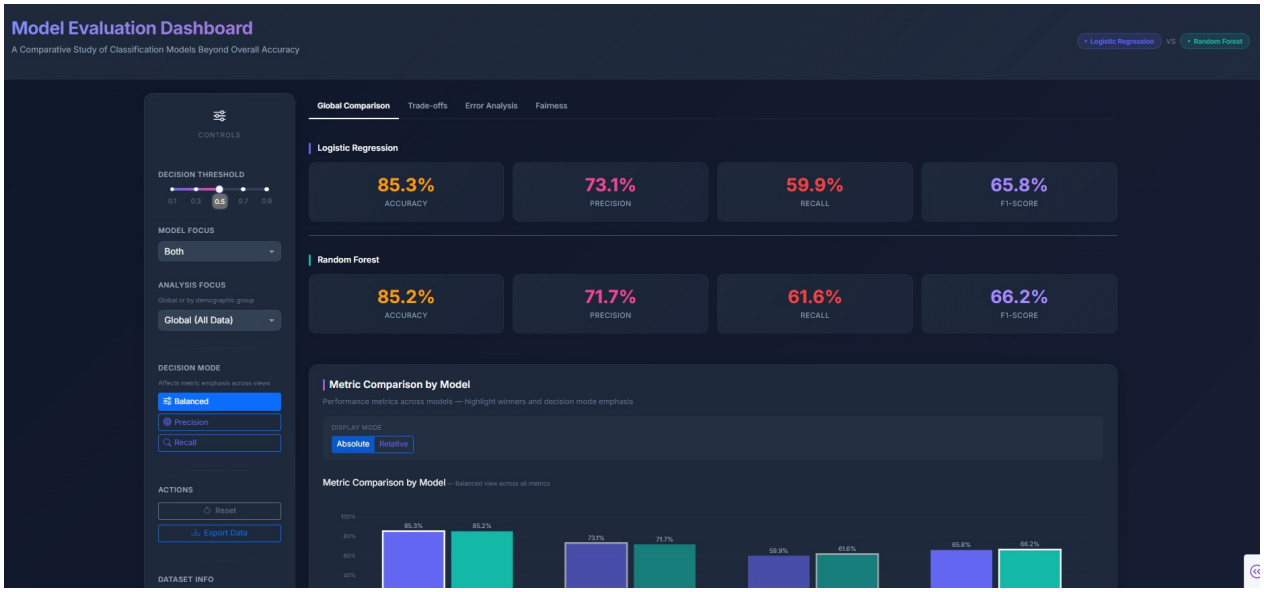

Figure 1.1: Visão geral do Model Evaluation Dashboard, mostrando os principais controlos e as vistas coordenadas para comparação global, exploração de trade-offs, análise de erros e avaliação de fairness.

1.2 Dados e Análise de Tarefas

O sistema desenvolvido baseia-se no *Adult Income Dataset* [1], um conjunto de dados para classificação binária cujo objetivo é prever se o rendimento anual de um indivíduo é superior ou inferior a 50K, com base em atributos sociodemográficos e profissionais. O conjunto de dados inclui variáveis numéricas e categóricas e apresenta uma distribuição de classes desequilibrada, com predominância da classe negativa (<50K), o que torna particularmente relevante a análise de métricas para além da *accuracy*.

Neste contexto, os modelos produzem, para cada instância, uma probabilidade associada à classe positiva, sendo a decisão final determinada por um *threshold*. A escolha deste limiar introduz um compromisso entre diferentes tipos de erro, pelo que a avaliação do desempenho não pode ser reduzida a uma única métrica.

Com base nesta caracterização, foram definidas as principais tarefas analíticas do sistema: (i) comparar diretamente os modelos segundo diferentes critérios de avaliação; (ii) explorar o impacto do *threshold* nas métricas e nos erros; (iii) analisar detalhadamente os erros, incluindo a distribuição de falsos positivos e falsos negativos; (iv) avaliar *fairness* por subgrupos demográficos, como *sex* ou *race*; e (v) explorar *operating points* que representam diferentes compromissos entre múltiplos

critérios.

Estas tarefas foram operacionalizadas através de vistas coordenadas no dashboard, cada uma focada num aspeto específico da análise, mas ligadas entre si por controlos globais, como a seleção do modelo e o *threshold* de decisão.

1.3 Objetivos e Decisões de Design

O design do *Model Evaluation Dashboard* foi orientado por objetivos derivados do problema de avaliação de modelos de classificação e de princípios de visualização de informação. Em vez de apresentar apenas métricas agregadas, o sistema foi concebido para suportar uma análise exploratória, comparativa e orientada à decisão, com foco nos *trade-offs*, nos erros e nas implicações de *fairness*.

1.3.1 Objetivos de Design

O primeiro objetivo foi permitir a **comparação multi-métrica** entre modelos, possibilitando a observação simultânea de métricas como *accuracy*, *precision*, *recall* e *F1-score*. Um segundo objetivo consistiu em suportar a **exploração interativa de trade-offs**, permitindo variar o *threshold* e observar de imediato o impacto nas métricas e nos erros.

Outro objetivo central foi garantir a **ligação entre vistas** (*coordinated multiple views*), assegurando que as diferentes visualizações reagem de forma consistente às mesmas interações globais. Adicionalmente, a **fairness** foi tratada como uma dimensão de primeira classe no sistema, com uma vista dedicada à análise de disparidades entre subgrupos. Por fim, o sistema foi concebido para **escalar a múltiplos critérios e cenários de análise**, mantendo legibilidade e coerência visual.

1.3.2 Decisões de Design

Para concretizar estes objetivos, optou-se por um **dashboard multi-vista**, organizado em abas temáticas: *Global Comparison*, *Trade-offs*, *Error Analysis* e *Fairness*. Esta organização permite estruturar a análise em etapas lógicas e gerir a complexidade da informação apresentada.

O **threshold de decisão** foi implementado como um controlo global, garantindo consistência entre as diferentes vistas. Foi também adotada uma **codificação cromática consistente** para os modelos ao longo de todo o sistema, de forma a facilitar a comparação visual e reduzir a carga cognitiva do utilizador.

1.3.3 Justificação das Opções

A opção por não utilizar apenas a *accuracy* como métrica principal decorre do facto de esta poder ser enganadora, sobretudo em conjuntos de dados desbalanceados. Métricas como *precision*, *recall*, *F1-score* e curvas ROC/PR fornecem uma caracterização mais rica do desempenho e dos compromissos

entre diferentes critérios.

A **interatividade** foi considerada essencial, pois permite explorar diferentes cenários e compreender as relações entre parâmetros e resultados, algo que não é possível com visualizações estáticas. As Figuras 1.2 e 1.1 ilustram, respetivamente, um esboço inicial do layout do dashboard e a versão final implementada, evidenciando a evolução do design até uma solução mais integrada e analítica.

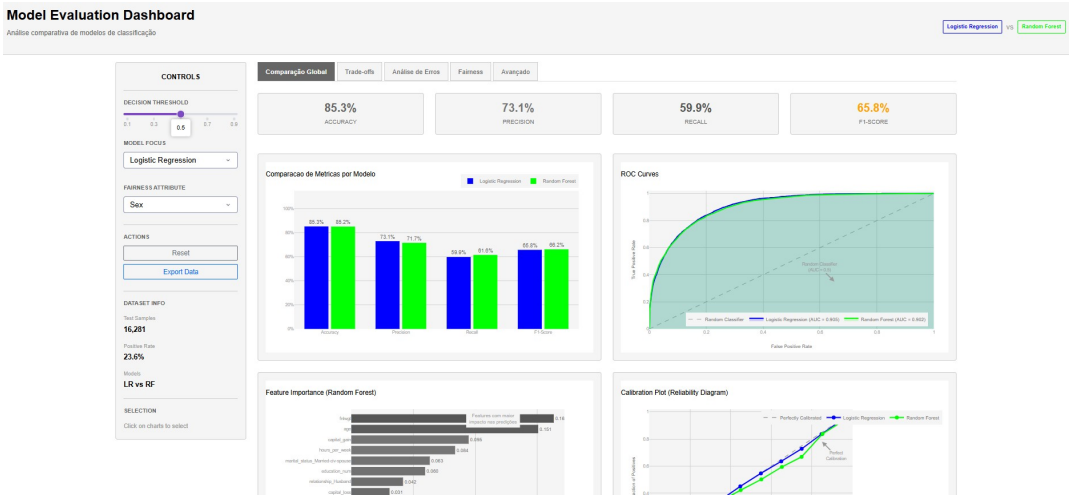

Figure 1.2: Esboço inicial do layout do dashboard.

1.4 Processo de Design Iterativo

Esta secção descreve o processo iterativo de conceção do dashboard, com foco nas decisões de design mais relevantes e nas visualizações mais expressivas desenvolvidas ao longo do projeto. Em vez de descrever todos os gráficos individuais, são destacados três componentes centrais: o *Horizon Graph* para análise de fairness, o *Connected Bubble Scatter Plot* para análise de erros, e o gráfico de *Parallel Coordinates* para análise de *operating points*. É também apresentado o papel do painel de controlos global, responsável pela coordenação entre vistas.

1.4.1 Da Visualização Básica às Vistas Analíticas

As primeiras versões do dashboard baseavam-se em gráficos simples, como gráficos de barras e indicadores numéricos, para comparar métricas entre modelos e subgrupos. Embora fáceis de interpretar, estas visualizações eram demasiado estáticas e não permitiam analisar a evolução das métricas com o *decision threshold*, nem identificar padrões ao longo do espaço de decisão.

Um exemplo desta abordagem inicial é mostrado na Figura 1.3, onde a fairness é representada apenas por barras agregadas por grupo. Esta representação permite comparações pontuais, mas não revela tendências nem variações ao longo do threshold, motivando a transição para visualizações mais expressivas e orientadas à exploração.

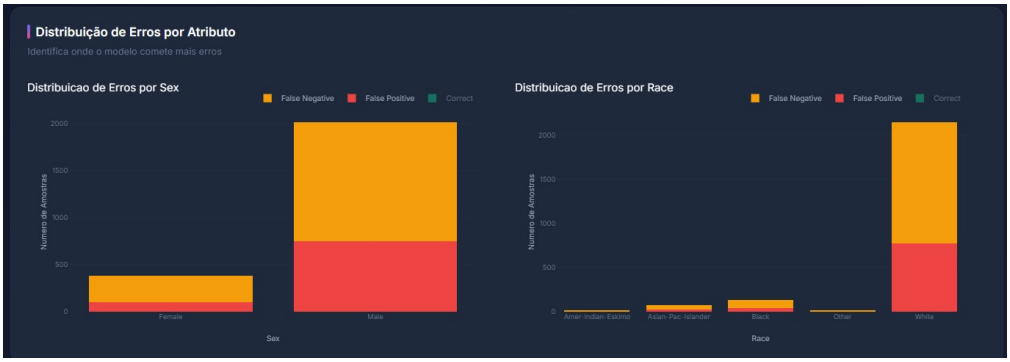

Figure 1.3: Protótipo inicial baseado em gráficos de barras para análise de fairness, que não revela padrões ao longo do *decision threshold*.

1.4.2 Fairness ao Longo do Threshold com Horizon Graph

Para analisar fairness de forma contínua ao longo do *decision threshold*, foi introduzido um *Horizon Graph*, apresentado na Figura 1.4. Esta técnica permite representar séries paramétricas de forma compacta, utilizando bandas de cor para codificar a magnitude dos valores.

No dashboard, o *Horizon Graph* mostra a evolução de métricas de erro para diferentes grupos demográficos à medida que o threshold varia, bem como a disparidade absoluta entre grupos. Comparado com o gráfico de barras inicial, esta visualização revela padrões globais, tendências e regiões críticas do espaço de decisão, permitindo perceber não só se existe disparidade, mas também onde e em que condições ela é mais acentuada.

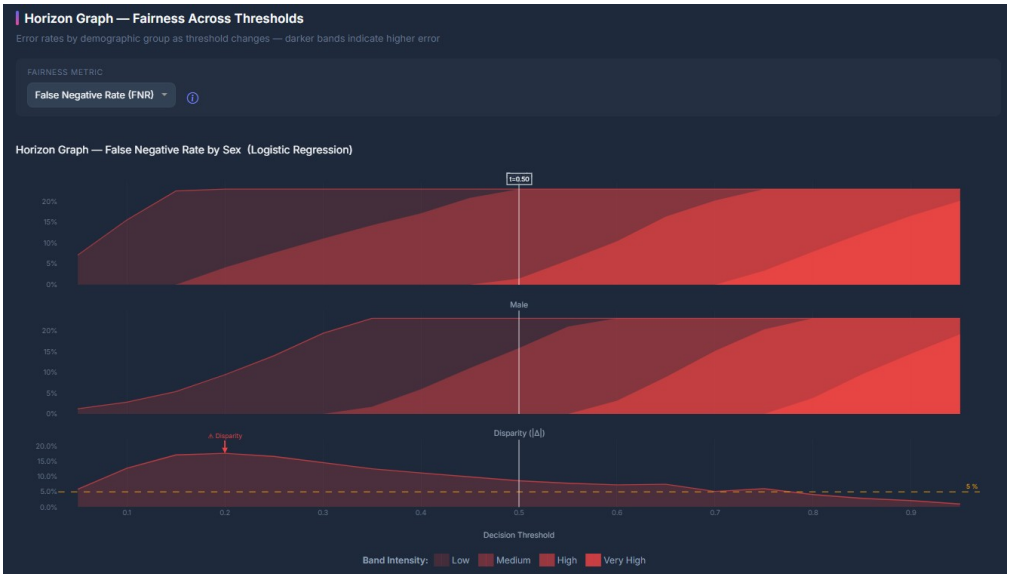

Figure 1.4: Horizon Graph para análise de fairness ao longo do *decision threshold*.

1.4.3 Error Trade-off Trajectories

Para a análise de erros, foi desenvolvido o gráfico de *Connected Bubble Scatter Plot*, mostrado na Figura 1.5. Esta visualização representa a trajetória de cada modelo no espaço definido por *False*

Positive Rate (FPR) e *False Negative Rate* (FNR), à medida que o *decision threshold* varia.

Cada ponto da curva corresponde a um threshold específico, permitindo observar como pequenas variações deste parâmetro deslocam o modelo no espaço de erros. Esta abordagem transforma uma variação dinâmica num percurso estático comparável entre modelos, tornando explícito o trade-off entre diferentes tipos de erro.

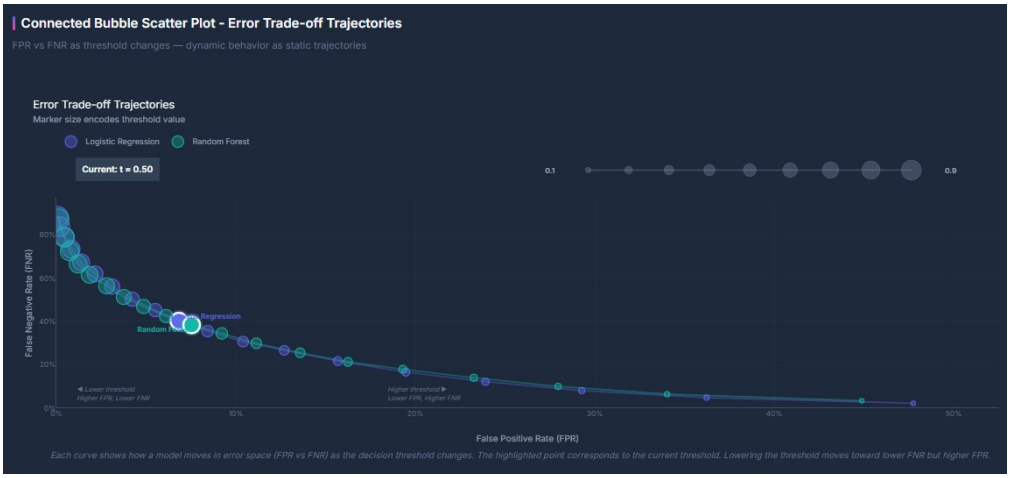

Figure 1.5: Error Trade-off Trajectories: evolução de cada modelo no espaço FPR vs FNR ao variar o *decision threshold*.

1.4.4 Parallel Coordinates para Análise de Operating Points

Para suportar a análise multidimensional de *operating points*, foi introduzido um gráfico de *Parallel Coordinates*, apresentado na Figura 1.6. Cada linha representa uma configuração específica (modelo, threshold e subgrupo) e cada eixo corresponde a uma métrica diferente.

Esta técnica permite comparar simultaneamente múltiplos critérios e explorar compromissos entre desempenho, erro e fairness. A interação por *brushing* possibilita filtrar subconjuntos de soluções e observar como essas escolhas se refletem nas métricas e noutras vistas do dashboard.

1.4.5 Painel de Controlo Global e Vistas Coordenadas

Um elemento central do sistema é o painel de controlos global, apresentado na Figura 1.7. Este painel permite ajustar o *decision threshold*, escolher o modelo em foco e selecionar o subgrupo de análise, afetando simultaneamente todas as vistas do dashboard.

Este mecanismo garante consistência entre as representações e transforma o sistema numa ferramenta de análise exploratória coordenada, onde uma única interação se reflete em múltiplas perspetivas complementares.

Em conjunto, estas visualizações avançadas e o sistema de controlos globais representam a evolução do projeto de um conjunto de gráficos descritivos para uma ferramenta de análise visual integrada, orientada à exploração, comparação e apoio à decisão.

Figure 1.6: Gráfico de Parallel Coordinates para análise de *operating points*.

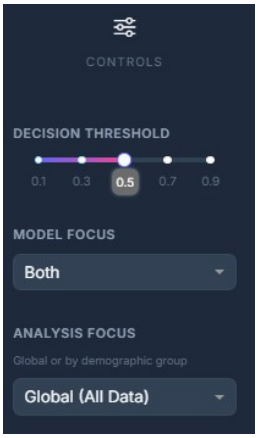

Figure 1.7: Painel de controlos global, que coordena todas as vistas do dashboard.

Chapter 2

Insights, Limitações e Reflexão Final

2.1 Insights & Reflections

Uma das principais motivações deste projeto foi utilizar a visualização como ferramenta de análise e não apenas como meio de apresentação de resultados. Ao longo do desenvolvimento do dashboard, várias conclusões relevantes emergiram diretamente da exploração visual dos dados, em particular através das vistas avançadas dedicadas a trade-offs, erros e fairness.

2.1.1 Insights Obtidos Através da Visualização

Um insight fundamental é o impacto do *decision threshold* na disparidade entre grupos. A Figura 2.1 mostra o *Horizon Graph* da taxa de falsos positivos (FPR) por sexo para a Random Forest. Observa-se que, para valores baixos de threshold, tanto o grupo feminino como o masculino apresentam taxas de erro mais elevadas, mas a magnitude e a forma da curva diferem entre os dois grupos. Mais importante ainda, a vista inferior de disparidade mostra que a diferença entre grupos não é constante: existe uma região do espaço de decisão onde a disparidade é claramente mais acentuada e outra onde se aproxima de zero. Este resultado evidencia que a fairness não é uma propriedade fixa de um modelo, mas sim algo que depende fortemente da configuração da decisão.

Outro insight relevante surge da análise conjunta de desempenho e calibração. Em alguns intervalos de threshold, é possível observar configurações com bom compromisso entre precisão e recall, mas com pior comportamento em termos de calibração ou fairness. Isto evidencia a existência de trade-offs reais entre diferentes critérios de qualidade do modelo, reforçando a importância de não otimizar apenas uma métrica isolada.

Finalmente, as vistas de *Error Trade-off Trajectories* e de *Parallel Coordinates* mostram que pequenas variações no threshold podem deslocar significativamente o modelo no espaço de erros e nas métricas globais. Esta sensibilidade seria difícil de perceber apenas com tabelas de números ou métricas pontuais, mas torna-se evidente quando observada através de trajetórias e representações multidimensionais.

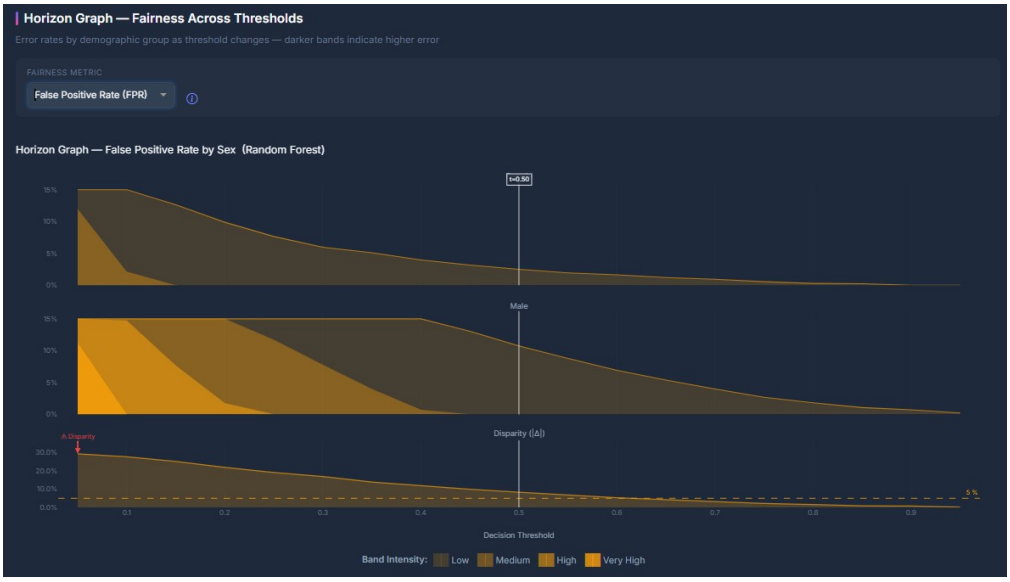

Figure 2.1: Horizon Graph da taxa de falsos positivos (FPR) por sexo para a Random Forest. As duas primeiras bandas mostram a evolução do erro para cada grupo, e a terceira mostra a disparidade absoluta entre eles.

2.2 Conclusão e Reflexão Final

Uma das principais lições deste projeto é que a visualização é uma ferramenta essencial para compreender sistemas complexos de decisão. Métricas isoladas raramente contam a história completa, e apenas através de vistas interativas e coordenadas é possível explorar trade-offs, identificar padrões e descobrir problemas que não são visíveis à primeira vista.

O trabalho também mostrou a importância da interatividade: poder variar o threshold, mudar o foco da análise e observar imediatamente o impacto em múltiplas vistas transforma a análise num processo exploratório e iterativo, em vez de uma simples consulta de resultados estáticos. Por fim, tornou-se claro que fairness não é um valor fixo associado a um modelo, mas sim uma propriedade dependente do contexto e das escolhas de decisão, algo que só se torna evidente quando representado e explorado visualmente.

Bibliography

[1] Barry Becker. *UCI Machine Learning Repository: Adult Data Set*. URL: https://archive.ics.uci.edu/dataset/2/adult.